# Projet Pratique : Plateforme d'Analyse et de Visualisation d'Audience Média

Module : Visualisation de Données avec Python

## Présentation et Objectifs du Projet

L'objectif de ce projet est de concevoir et déployer une solution complète de visualisation de données et un tableau de bord interactif permettant d'analyser, d'explorer et d'interpréter les données de fréquentation ou d'usage d'une plateforme (médias en ligne, e-commerce, réseaux sociaux ou services publics).

Le projet permettra de mettre en pratique l'intégralité de la chaîne de traitement de données : du nettoyage initial avec `Pandas` à la création d'un dashboard interactif déployé sous `Streamlit` ou `Plotly Express`.

---

## 1 Données d'Entrée et Sources Open Data

### 1.1 Critères de sélection des données

Les étudiants peuvent travailler soit sur un jeu de données de fréquentation/audience fourni, soit sélectionner un jeu de données ouvert (*Open Data*) de leur choix respectant les contraintes minimales suivantes :

- Au moins **1 variable temporelle** (horodatage, date ou année) pour l'analyse des séries temporelles.
- Au moins **2 variables numériques** (durée, montant, nombre de vues, trafic, etc.).
- Au moins **2 variables catégorielles** (types de médias, appareils, catégories de produits, pays, etc.).

### 1.2 Sources Open Data recommandées

- **Kaggle Datasets :** Recherche des thématiques *"Web Traffic"*, *"User Behavior"*, ou *"E-commerce Clickstream"* (`https://www.kaggle.com/datasets`).
- **Our World in Data :** Jeux de données mondiaux sur l'accès aux technologies et médias (`https://ourworldindata.org`).
- **Plateformes publiques (Data.gouv / Banque Mondiale) :** Données publiques de transport, santé ou télécommunications.
- **Data intégre Plotly Express :** Possibilité d'utiliser directement `px.data.gapminder()` ou `px.data.stocks()`.

---

## 2 Cahier des Charges et Étape du Projet

### 2.1 Étape 1 : Nettoyage et Préparation des Données (*Data Engineering*)

1. Inspection de la structure du jeu de données et gestion des valeurs manquantes ou aberrantes.
2. Conversion des colonnes de dates au format `datetime` pour l'indexation temporelle.

3. Création de nouvelles variables agrégées (ex. extraction de l'heure, du jour de la semaine ou du mois).

### 2.2 Étape 2 : Calcul des Indicateurs Clés (KPI)

Calcul des métriques globales restituées sous forme de cartes d'indicateurs :
— Volume total de visites / sessions ou transactions.
— Durée moyenne ou valeur moyenne par session.
— Répartition de l'audience par type d'appareil ou catégorie.

### 2.3 Étape 3 : Conception des Visualisations Interactives

Création de visualisations à l'aide de `Seaborn` et `Plotly Express` :

1. **Évolution Temporelle :** Courbe d'évolution du trafic au fil du temps avec filtres interactifs.
2. **Comparaison Catégorielle :** Diagramme en barres ou camembert comparant les parts de trafic par catégorie ou média.
3. **Analyse de Distribution :** Boxplot ou diagramme de densité comparant l'engagement selon le type d'appareil.
4. **Matrice de Corrélation / Heatmap :** Carte thermique croisant les heures de pointe et les jours de la semaine.

### 2.4 Étape 4 : Développement de l'Application Streamlit

Intégration de l'ensemble des analyses dans un tableau de bord interactif (`app.py`) comportant :
— Un panneau latéral (`st.sidebar`) pour le filtrage dynamique par période, catégorie ou appareil.
— L'affichage dynamique des métriques clés (`st.metric`).
— L'intégration des graphiques Plotly Express (`st.plotly_chart`).
— Un bouton d'export des données filtrées au format CSV (`st.download_button`).

---

## 3 Livrables Attendus

1. **Code Source :** Un dépôt ou fichier d'application Streamlit (`app.py`) propre et commenté, accompagné du notebook de pré-traitement (`.ipynb`).
2. **Rapport d'Analyse :** Un document synthétique présentant le jeu de données choisi, la démarche de nettoyage, l'interprétation des graphiques et les conclusions business/techniques.
3. **Démonstration :** Une présentation orale du tableau de bord interactif.