Audience Lab

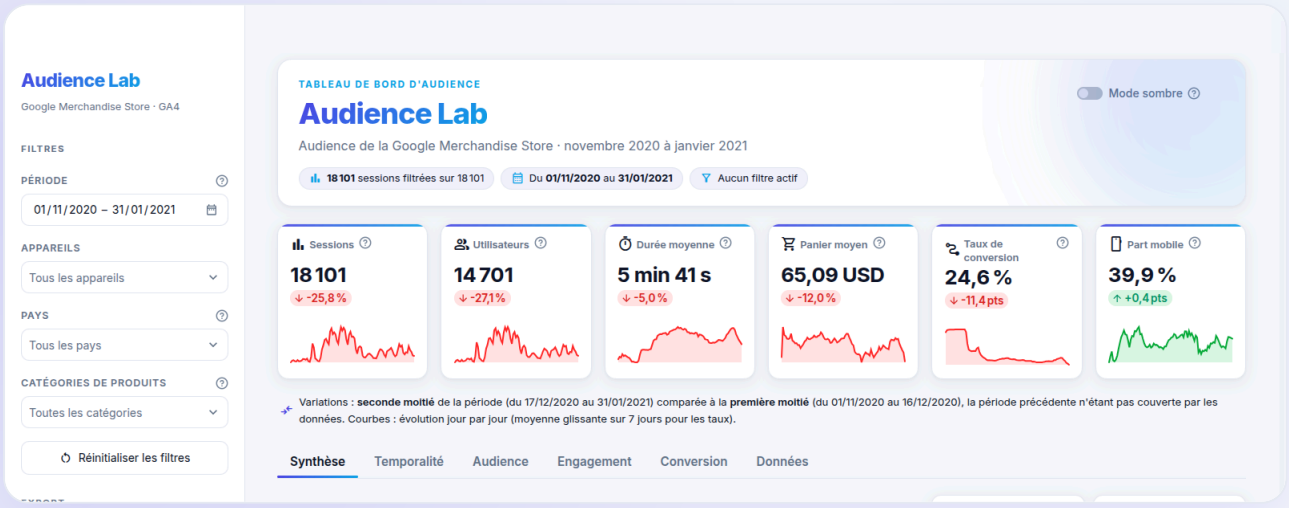
RAPPORT D'ANALYSE

PROJET PRATIQUE · PLATEFORME D'ANALYSE ET DE VISUALISATION D'AUDIENCE

Audience Lab

Qui visite la Google Merchandise Store, quand, sur quel appareil, et où la boutique perd-elle ses acheteurs ? Analyse de 18 101 sessions GA4, de novembre 2020 à janvier 2021.

18 101	14 701	24,56 %	289 407 USD
sessions analysées	utilisateurs distincts	taux de conversion	chiffre d'affaires



AUTEUR

Abdoul-Aziz ZOROM

Master 1 Intelligence Artificielle
Université Aube-Nouvelle

MODULE

Visualisation de Données avec Python
Enseignant : Dr. Zakaria Sawadogo
19 octobre 2026

DÉPÔT DU CODE
github.com/Abdazz/audience-lab

APPLICATION EN LIGNE
https://audience-lab.streamlit.app

PLAN DU RAPPORT

Table des matières

0 Synthèse : l'essentiel en une page 3

1 Contexte et objectifs 4

2 Le jeu de données 5

- 2.1 Source, licence et période 5
- 2.2 Structure et variables 5
- 2.3 Critères du sujet et justification du choix 6

3 Démarche de nettoyage et de préparation 6

- 3.1 Bilan chiffré, étape par étape 6
- 3.2 Décisions de nettoyage 7
- 3.3 Valeurs aberrantes : signaler plutôt que supprimer 7

4 Indicateurs clés 8

5 Analyse visuelle 9

- 5.1 Évolution temporelle du trafic 9
- 5.2 Comparaison catégorielle : produits et pays 10
- 5.3 Distribution de l'engagement par appareil 11
- 5.4 Heatmap heure x jour de la semaine 11
- 5.5 Compléments : entonnoir de conversion et corrélations 12

6 Le tableau de bord Audience Lab 13

7 Conclusions business 16

8 Conclusions techniques et limites 17

A Annexes 18

- A.1 Exécution locale 18
- A.2 Arborescence du dépôt 19
- A.3 Correspondance avec les exigences du sujet 19
- A.4 Sources et références 19

Conventions. Les valeurs des données restent dans leur langue d'origine (`desktop`, `mobile`, `tablet`, `add_to_cart`, `begin_checkout`, `purchase`, `Apparel`, noms de pays en anglais) ; tout le reste est en français. Les montants sont en dollars américains (USD). Sauf mention contraire, les chiffres portent sur la période complète (1er novembre 2020 au 31 janvier 2021) et proviennent du notebook `notebooks/01_preparation_donnees.ipynb`, exécuté de bout en bout ; l'application affiche les mêmes valeurs.

RÉSUMÉ EXÉCUTIF

00 Synthèse : l'essentiel en une page

Ce projet traite le trafic d'une boutique en ligne réelle, la Google Merchandise Store, comme l'audience d'un média. À partir de 758 884 événements bruts issus de Google Analytics 4, nous avons reconstitué 18 101 sessions, calculé les indicateurs clés et construit un tableau de bord interactif, Audience Lab, qui permet d'explorer cette audience par période, appareil, pays et catégorie de produit.

18 101	24,56 %	65,09 USD	x 2,47
sessions de 14 701 utilisateurs	des sessions se terminent par un achat	panier moyen d'une session avec achat	trafic quotidien de décembre comparé à novembre

Quatre constats

1 Une audience très saisonnière

Après un pic isolé les 17 et 18 novembre (287 et 229 sessions), au lendemain du démarrage de la collecte des ajouts au panier, la hausse durable commence le 24 novembre. Le trafic culmine dans la première quinzaine de décembre : record le 8 décembre 2020 avec 527 sessions. Le jour de Noël ne compte que 87 sessions.

2 Un trafic de semaine

Le mardi (3 180 sessions) attire 1,9 fois plus de visites que le dimanche (1 673) ; le week-end ne pèse que 20,0 % des sessions. L'heure, en revanche, discrimine très peu (681 à 789 sessions selon l'heure).

3 L'appareil ne fait pas la différence

Le mobile représente 39,9 % du trafic et 41,0 % des achats. Les taux de conversion sont presque identiques (24,1 % desktop, 25,2 % mobile, 23,9 % tablet), de même que les durées médianes.

4 Les acheteurs se perdent au panier

Seules 35,0 % des sessions avec ajout au panier commencent un paiement, puis 47,1 % des paiements commencés aboutissent. `Apparel` porte 54,3 % du chiffre d'affaires.

Trois recommandations prioritaires

À RETENIR POUR LA DÉCISION (DÉTAIL EN SECTION 7)

1. **Préparer la fenêtre du 23 novembre au 18 décembre**, qui concentre 53,8 % des sessions en 26 jours : campagnes lancées avant le Black Friday, stocks et messages sur les dates limites de livraison.
2. **Travailler le passage du panier au paiement**, étape où 65,0 % des sessions concernées s'arrêtent : relance de panier, frais de livraison affichés tôt, paiement express.
3. **Programmer les actions en semaine**, mardi et mercredi en tête, et traiter le mobile à parité avec le desktop plutôt que comme un canal à « rattraper ».

Livrables : notebook de préparation (`notebooks/01_preparation_donnees.ipynb`), application Streamlit (`app.py`, en ligne à l'adresse https://audience-lab.streamlit.app), présent rapport et dépôt github.com/Abdazz/audience-lab.

CADRE DU PROJET

01 Contexte et objectifs

Le sujet demande de concevoir une plateforme d'analyse et de visualisation de l'audience d'un service en ligne : nettoyer des données de fréquentation, en extraire des indicateurs, les représenter avec Seaborn et Plotly Express, puis les intégrer dans un tableau de bord Streamlit déployé.

Une boutique en ligne lue comme un média

Le sujet autorise les médias en ligne, l'e-commerce, les réseaux sociaux ou les services publics. Nous avons retenu l'e-commerce, avec un jeu de données de mesure d'audience réel : celui de la Google Merchandise Store, collecté par Google Analytics 4, l'outil de référence de la mesure d'audience web. Une **session** y joue le rôle d'une visite, l'**appareil** celui du support de consultation, et l'**entonnoir d'achat** celui de la fidélisation d'un lectorat : on mesure combien de visiteurs vont au bout de leur parcours.

Quatre questions directrices

Question	Ce que l'on mesure	Onglet de l'application
Quand les visiteurs viennent-ils ?	Saisonnalité (jour, semaine), jours et heures de pointe	Temporalité
D'où et sur quel appareil ?	Parts par appareil, par pays et par catégorie de produit	Audience
À quel point s'engagent-ils ?	Durée de session, nombre d'actions, valeur ajoutée au panier	Engagement
Où les perd-on ?	Entonnoir `add_to_cart`, `begin_checkout`, `purchase`	Conversion

Démarche : de la donnée brute à la décision

La chaîne de traitement suit les quatre étapes du cahier des charges. Chaque maillon produit un artefact versionné dans le dépôt, ce qui rend l'ensemble reproductible.

Données brutes
3 fichiers CSV (`data/raw/`), téléchargeables par script

→

Préparation
Notebook pandas : nettoyage, sessions, KPI, figures Seaborn

→

Données traitées
2 fichiers Parquet (4,8 Mo au total)

→

Tableau de bord
Streamlit et Plotly Express, filtres, KPI, export CSV

→

Restitution
Rapport d'analyse et soutenance

Outils

Python 3.12 ; pandas 3.0.6 et pyarrow 26.0.0 pour la préparation ; seaborn 0.13.2 et matplotlib 3.11.2 pour les figures statiques ; Plotly 7.1.0 et Streamlit 1.66.0 pour l'application ; pycountry pour les noms de pays ; pytest pour les tests automatisés (95 tests). Les versions sont figées dans `requirements.txt`.

ORGANISATION DU RAPPORT

La section 2 présente le jeu de données et la section 3 la démarche de nettoyage, chiffrée étape par étape. La section 4 donne les indicateurs clés, la section 5 interprète chacun des graphiques imposés par le sujet, et la section 6 décrit le tableau de bord. Les sections 7 et 8 tirent les conclusions business, puis techniques, avec les limites de l'étude. Les annexes indiquent comment tout réexécuter et où trouver chaque exigence du sujet.

PRÉSENTATION DES DONNÉES

02 Le jeu de données

Les données proviennent de la Google Merchandise Store, la boutique officielle de produits dérivés Google (vêtements, sacs, papeterie, accessoires). Elles décrivent trois mois d'événements e-commerce, couvrant le Black Friday, les fêtes de fin d'année et le creux de janvier.

2.1 Source, licence et période

Origine	Sous-ensemble du jeu public BigQuery `ga4_obfuscated_sample_ecommerce`, publié par Google comme jeu de démonstration de Google Analytics 4.
Diffusion utilisée	Observable (`@observablehq/google-merchandise-sales-data`), reprise sur Kaggle (`mexwell/google-merchandise-sales-data`). Les fichiers sont récupérés par `scripts/telecharger_donnees.py`, qui contrôle l'en-tête et le nombre de lignes de chacun.
Licence et usage	Kaggle indique une licence « Other » renvoyant à la source Observable. Il s'agit d'un jeu de démonstration diffusé publiquement par Google, utilisé ici à des fins pédagogiques non commerciales, source citée. Les identifiants sont **obfusqués** par Google : aucune donnée personnelle.
Période	Du 1er novembre 2020 (00:27:14) au 31 janvier 2021 (23:59:08), soit 92 jours.

2.2 Structure et variables

Le jeu se compose de trois tables reliées par des identifiants. La table des événements est le cœur de l'analyse ; le catalogue l'enrichit des prix et des catégories ; la table des utilisateurs complète l'inventaire.

Fichier	Lignes	Colonnes	Contenu	Clé
`events.csv`	758 884	7	un événement e-commerce par ligne : ajout au panier, début de paiement ou achat	`user_id` + `ga_session_id`
`items.csv`	1 381	6	catalogue : nom, marque, variante, catégorie (21 valeurs), prix de 1 à 313 USD	`id`
`users.csv`	270 154	3	valeur vie client (`ltv`) et date de première visite	`id`

Variable	Nature	Description et modalités
`date` devenue `timestamp`	temporelle	horodatage à la seconde de l'événement, stocké en texte dans le fichier brut
`device`	catégorielle	`desktop` (441 521 événements bruts), `mobile` (300 628), `tablet` (16 735)
`type`	catégorielle	`add_to_cart` (667 282), `begin_checkout` (76 047), `purchase` (15 555)
`country`	catégorielle	code pays ISO à deux lettres : 108 pays, plus 4 555 valeurs manquantes
`item_category`, `item_brand`	catégorielle	21 catégories (`Apparel`, `Bags`, `Office`…) et 5 marques, après jointure du catalogue
`price_in_usd`, `ltv`	numérique	prix unitaire de l'article (USD) ; valeur vie client (positive pour 4 445 utilisateurs, soit 1,6 %)
`duration_s`, `n_events`, `n_items`	numérique dérivée	durée de session (secondes), nombre d'événements, nombre d'articles distincts
`cart_value_usd`, `revenue_usd`	numérique dérivée	valeur ajoutée au panier et chiffre d'affaires de la session (somme des prix des `add_to_cart`, puis des `purchase`)

2.3 Critères du sujet et justification du choix

Critère du sujet (section 1.1)	Variables qui le satisfont	Statut
Au moins 1 variable temporelle	horodatage à la seconde, d'où sont dérivés le jour, l'heure, le jour de la semaine et le mois	✓
Au moins 2 variables numériques	prix, `ltv`, durée de session, nombre d'événements, valeur du panier, chiffre d'affaires	✓
Au moins 2 variables catégorielles	appareil, type d'événement, pays, catégorie et marque de l'article	✓

Au-delà de ces critères, quatre raisons ont motivé ce choix :

- **Des données réelles de mesure d'audience**, produites par l'outil le plus utilisé du secteur, plutôt qu'un jeu synthétique.
- **Une forte saisonnalité** (Black Friday, Noël, janvier) qui donne du relief à l'analyse temporelle.
- **Un jeu relationnel** (trois tables) qui exige de vrais choix de préparation : jointures, construction des sessions, définition des indicateurs.
- **Un volume réaliste mais maîtrisable** (41,6 Mo de CSV pour les événements), compatible avec un déploiement gratuit sur Streamlit Community Cloud une fois converti en Parquet.

ÉTAPE 1 DU CAHIER DES CHARGES

03 Démarche de nettoyage et de préparation

Le notebook `notebooks/01_preparation_donnees.ipynb` part des trois fichiers bruts et documente chaque décision dans une cellule de texte. Le principe directeur : **ne rien supprimer sans preuve que la ligne est fausse**, et chiffrer l'effet de chaque étape.

3.1 Bilan chiffré, étape par étape

#	Étape	Avant	Après	Décision
1	Lecture et inspection	758 884	758 884	`info()`, `describe()`, cardinalités ; lecture avec `keep_default_na=False` pour que le code `NA` (Namibie) ne devienne pas une valeur manquante
2	Valeurs manquantes de `country`	4 555 manquants	0 manquant	remplacées par `(not set)`, convention de Google Analytics ; aucune ligne supprimée
3	Doublons exacts	758 884	719 386	39 498 lignes (5,20 %) identiques sur les sept colonnes supprimées
4	Conversion des dates	texte	datetime64	`pd.to_datetime` avec format explicite ; indexation par `set_index` et agrégation par `resample`
5	Jointure du catalogue et des pays	719 386	719 386	jointure à gauche validée `many_to_one`, 0 article sans correspondance ; codes ISO-3 et noms par pycountry
6	Variables dérivées	7 colonnes	18 colonnes	jour, heure, jour de la semaine (0 = lundi), mois, clé de session
7	Agrégation en sessions	719 386 évén.	18 101 sessions	une ligne par session, 22 variables, 14 701 utilisateurs
8	Valeurs aberrantes (IQR)	18 101	18 101	3 000 sessions (16,6 %) signalées par deux indicateurs booléens, toutes conservées
9	Export Parquet	41,7 Mo	4,8 Mo	`events_clean.parquet` (3,9 Mo) et `sessions.parquet` (0,9 Mo), types conservés

Effectifs en lignes d'événements, sauf mention contraire. La taille « avant » de l'étape 9 est celle de `events.csv` et `items.csv`.

3.2 Décisions de nettoyage

Valeurs manquantes : expliciter plutôt que supprimer ou inventer

Seule la colonne `country` présente des manquants : 4 555 événements, soit 0,6 %. Ils forment **136 sessions entièrement sans pays** et aucune session partiellement renseignée : il s'agit d'un échec de géolocalisation de la visite, pas d'une erreur de saisie isolée. Supprimer ces lignes ferait perdre 136 sessions réelles, avec leurs achats ; imputer le pays le plus fréquent (`US`) inventerait une information et fausserait la carte. La modalité `(not set)`, que Google Analytics emploie lui-même, reste visible et filtrable. Dans le catalogue, la colonne `variant` compte 408 manquants, mais elle n'est pas utilisée.

Doublons : des envois répétés du marqueur

Un doublon exact est identique sur les sept colonnes, horodatage à la seconde compris. Les 39 498 doublons concernent à 94,8 % l'événement `begin_checkout` (37 443 lignes), signe d'envois répétés du marqueur lors d'un rechargement de la page de paiement. Les conserver gonflerait les volumes et, pour `purchase` (844 doublons), compterait deux fois le même chiffre d'affaires. Limite assumée : deux ajouts réellement distincts du même article dans la même seconde seraient indiscernables.

Dates, enrichissement et table des sessions

La colonne `date` contient en réalité un horodatage, converti en `timestamp` ; on en dérive le jour, l'heure, le jour de la semaine et le mois (étape 1.3 du sujet). Le catalogue est joint sans perte ni duplication, et pycountry ajoute le code ISO-3 (pour la carte) et le nom anglais du pays ; le Kosovo (`XK`), absent de la norme, est complété à la main. Enfin, comme `ga_session_id` n'est unique qu'au sein d'un utilisateur (18 034 valeurs pour 18 101 sessions), la clé de session combine `user_id` et `ga_session_id`. La table des sessions agrège début, fin, durée, nombre d'événements et d'articles, valeur du panier, chiffre d'affaires et indicateurs d'étape. Des contrôles automatiques vérifient sa cohérence avec la table des événements : unicité de la clé, somme des événements, chiffre d'affaires, durées positives ou nulles, un seul appareil et un seul pays par session.

3.3 Valeurs aberrantes : signaler plutôt que supprimer

La règle de Tukey (valeur au-dessus de Q3 + 1,5 x IQR) est appliquée aux deux mesures d'engagement, sur l'ensemble des sessions. La borne basse, négative ou nulle, est sans objet.

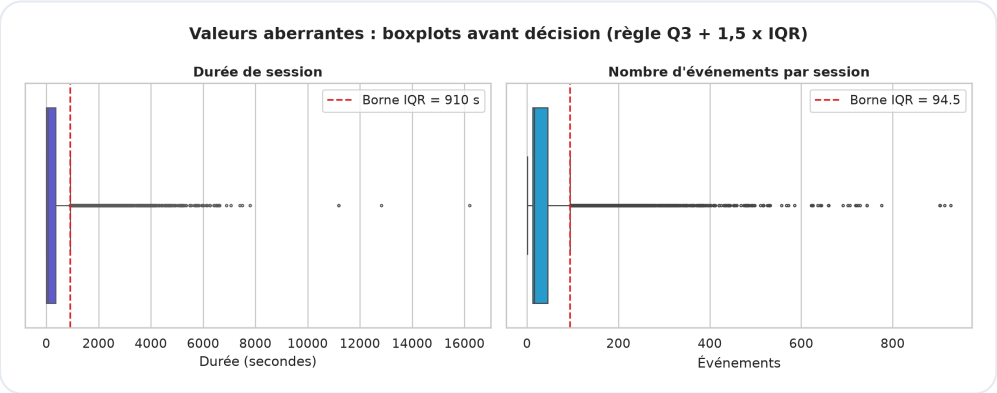


Figure 1. Boxplots avant décision. La ligne rouge marque la borne Q3 + 1,5 x IQR. Durée : Q1 = 0 s, Q3 = 364 s, borne de 910 s, dépassée par 2 075 sessions (11,5 %), maximum 16 196 s. Événements : Q1 = 12, Q3 = 45, borne de 94,5, dépassée par 1 901 sessions (10,5 %), maximum 927. Source : notebook, section 8.

POURQUOI CONSERVER CES 3 000 SESSIONS

Les boxplots montrent une queue continue, pas quelques points isolés : ce sont de vrais comportements (grosses commandes, onglet resté ouvert). Surtout, ces sessions convertissent à 47,1 % contre 20,1 % pour les sessions typiques, ont un panier moyen de 3 074 USD contre 514 USD et apportent **42,4 % du chiffre d'affaires** (122 823 USD). Les supprimer fausserait tous les indicateurs business. Elles sont donc signalées par `is_outlier_duration` et `is_outlier_events`, et les graphiques de distribution passent en échelle logarithmique plutôt que de les couper.

ÉTAPE 2 DU CAHIER DES CHARGES

04 Indicateurs clés

Les indicateurs sont calculés sur toutes les sessions, y compris celles signalées comme aberrantes. Ce sont les six cartes du bandeau de l'application, avec le même arrondi (valeur exacte en petit sous chaque taux), ici sur la période complète et sans filtre.

SESSIONS
18 101
volume total de visites ; 719 386 événements

UTILISATEURS
14 701
dont 2 374 reviennent au moins une fois

DURÉE MOYENNE
5 min 41 s
341,48 s en moyenne, mais 66 s en médiane

PANIER MOYEN
65,09 USD
montant moyen d'une session avec achat (médiane 47 USD)

TAUX DE CONVERSION
24,6 %
exactement 24,56 % ; 4 446 sessions avec achat

PART MOBILE
39,9 %
exactement 39,95 % ; 41,0 % des achats

Indicateurs complémentaires

Indicateur	Valeur
Chiffre d'affaires total	289 407 USD
Chiffre d'affaires par session	15,99 USD
Part des sessions atteignant le paiement	40,37 %
Événements par session (moyenne / médiane)	39,74 / 16
Valeur ajoutée au panier par session	938,63 USD
Part de la valeur du panier achetée	1,7 %

Audience par pays (sessions)

Pays	Sessions	Part
United States	7 993	44,2 %
India	1 667	9,2 %
Canada	1 408	7,8 %
United Kingdom	554	3,1 %
France	356	2,0 %
Top 10 (sur 108 pays et `(not set)`)	**13 470**	**74,4 %**

Répartition de l'audience par appareil

Appareil	Sessions	Part du trafic	Conversion	Durée médiane	Chiffre d'affaires	Part du CA
`desktop`	10 489	57,9 %	24,1 %	64 s	167 178 USD	57,8 %
`mobile`	7 231	39,9 %	25,2 %	69 s	116 474 USD	40,2 %
`tablet`	381	2,1 %	23,9 %	69 s	5 755 USD	2,0 %
Ensemble	**18 101**	**100 %**	**24,56 %**	**66 s**	**289 407 USD**	**100 %**

DEUX DÉFINITIONS À NE PAS CONFONDRE

Le **panier moyen** (65,09 USD) est le montant moyen d'une session *avec achat* : c'est l'indicateur retenu dans le bandeau. La **valeur ajoutée au panier** (938,63 USD par session) additionne les prix de tous les `add_to_cart`, même si un article est ajouté plusieurs fois et jamais acheté : seuls 1,7 % de cette valeur sont finalement achetés. Elle mesure l'intérêt, pas la dépense. De même, la durée **médiane** (66 s) décrit mieux la session typique que la moyenne (341,48 s), tirée par une longue traîne.

Part du chiffre d'affaires par appareil et total du top 10 : calcul complémentaire sur `data/processed/` ; autres valeurs : notebook, section 9.

ÉTAPE 3 DU CAHIER DES CHARGES

05 Analyse visuelle

Chaque visualisation imposée par le sujet a sa version statique Seaborn dans le notebook (reproduite ici à 200 dpi) et sa version interactive Plotly Express dans l'application, où elle réagit aux filtres. Les quatre premières sous-sections suivent l'ordre du sujet ; la dernière ajoute deux analyses utiles à la décision.

5.1 Évolution temporelle du trafic

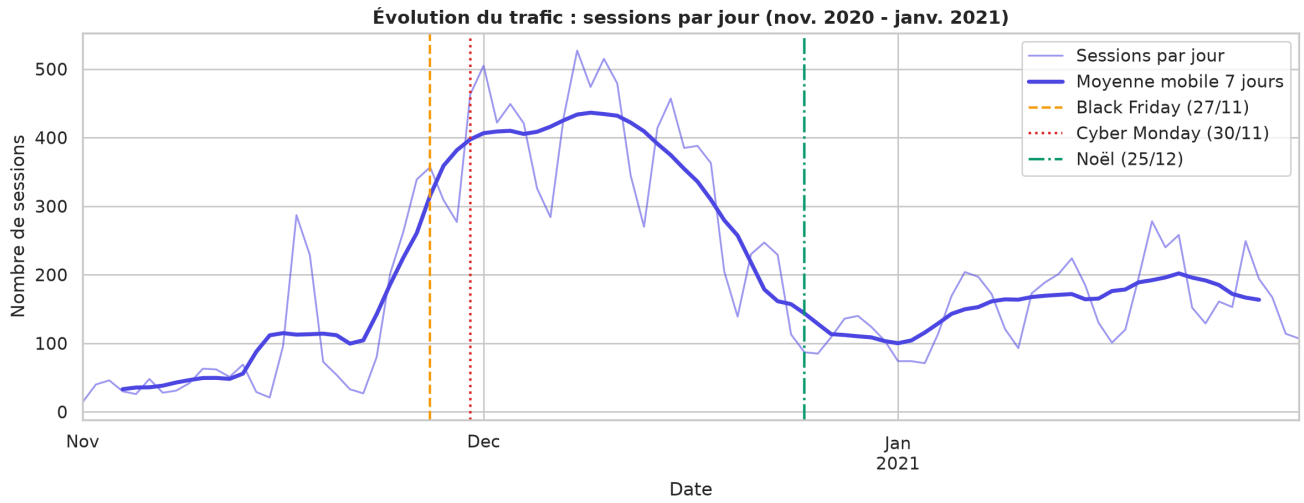


Figure 2. Sessions par jour et moyenne mobile sur 7 jours. Lignes verticales : Black Friday (27/11), Cyber Monday (30/11), Noël (25/12). Seaborn et matplotlib, `resample("D")` sur le début de session. Dans l'application : `px.line`, granularité jour ou semaine, détail par appareil. Source : notebook, section 10.1.

527 sessions
record du 8 décembre 2020 ; les 5 jours les plus actifs tombent entre le 1er et le 11 décembre

x 2,47
sessions par jour en décembre (303,3) comparées à novembre (122,9) ; janvier : 161,6

87 sessions
le jour de Noël, contre 463 au Cyber Monday et 357 au Black Friday

Lecture. Du 1er au 15 novembre, le trafic est faible (40 sessions par jour en moyenne). Un premier pic apparaît les 17 et 18 novembre (287 puis 229 sessions), au lendemain du 16 novembre, date à laquelle les ajouts au panier commencent à être collectés : il retombe dès le 19 (73 sessions) et ne marque donc pas encore la saison. La hausse durable commence le 24 novembre (201 sessions, contre 80 la veille et 27 le 22), juste avant le Black Friday, puis le trafic reste au-dessus de 400 sessions par jour en moyenne mobile pendant la première quinzaine de décembre : la semaine du 7 décembre totalise 3 041 sessions. Le Black Friday et le Cyber Monday lancent la saison, mais **le pic est la période des commandes de Noël**, avant les dates limites de livraison. Le trafic s'effondre ensuite (87 sessions le 25 décembre) puis reprend modérément en janvier.

Interprétation. La boutique fonctionne comme un média saisonnier : décembre réunit 51,9 % des sessions et 45,4 % du chiffre d'affaires. Le début de novembre reflète aussi la collecte (avant le 16 novembre, seuls les achats sont enregistrés, voir section 8) : la comparaison novembre-décembre surestime donc un peu l'écart, sans en changer le sens.

Mois	Sessions	Part des sessions	Sessions par jour	Chiffre d'affaires	Part du CA
Novembre 2020	3 688	20,4 %	122,9	107 142 USD	37,0 %
Décembre 2020	9 403	51,9 %	303,3	131 454 USD	45,4 %
Janvier 2021	5 010	27,7 %	161,6	50 811 USD	17,6 %

Sessions et chiffre d'affaires par mois : calcul complémentaire sur `data/processed/sessions.parquet` ; sessions par jour : notebook, section 10.1.

5.2 Comparaison catégorielle : produits et pays

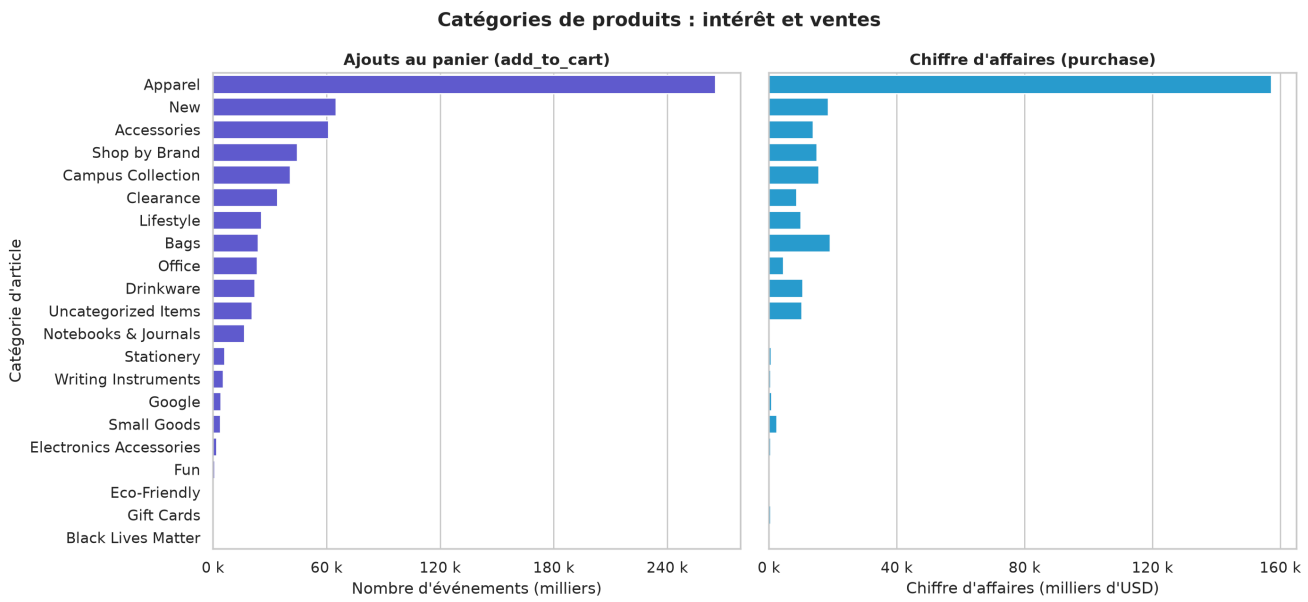


Figure 3. Intérêt (ajouts au panier) et ventes (chiffre d'affaires) par catégorie. `sns.barplot`, catégories triées par volume d'événements. Dans l'application : `px.bar` avec choix de la mesure, et `px.pie` en anneau pour les parts par appareil. Source : notebook, section 10.2.

Catégorie	Ajouts au panier	Achats	Chiffre d'affaires	Part du CA	Achats pour 100 ajouts	Prix moyen d'achat
`Apparel`	265 434	4 858	157 235 USD	54,3 %	1,83	32,37 USD
`Bags`	23 851	671	19 137 USD	6,6 %	2,81	28,52 USD
`New`	65 046	1 397	18 506 USD	6,4 %	2,15	13,25 USD
`Office`	23 343	798	4 501 USD	1,6 %	3,42	5,64 USD
`Notebooks & Journals`	16 514	36	246 USD	0,1 %	0,22	6,83 USD

Lecture. `Apparel` écrase toutes les autres catégories : 39,3 % des événements, 265 434 ajouts au panier et 54,3 % du chiffre d'affaires. Les trois premières catégories réunissent 58,8 % des ajouts au panier.

Interprétation. L'intérêt ne se traduit pas toujours en ventes. `Bags` n'est que 8e en ajouts au panier mais **2e en chiffre d'affaires** : ce n'est pas un effet de prix (28,52 USD par achat contre 32,37 USD pour `Apparel`), mais une meilleure transformation, avec 2,81 achats pour 100 ajouts contre 1,83. À l'inverse, `Notebooks & Journals` cumule 16 514 ajouts pour 36 achats seulement (0,22 pour 100) : une catégorie très regardée, presque jamais achetée, qui mérite un audit. Les catégories marginales (`Fun`, `Eco-Friendly`, `Gift Cards`, `Black Lives Matter`) pèsent moins de 1 % des événements.

Pays. L'audience est d'abord américaine : 44,2 % des sessions viennent des États-Unis, 61,1 % des trois premiers pays (avec l'Inde et le Canada) et 74,4 % du top 10. La conversion y est comparable (24,2 % aux États-Unis, 24,9 % en Inde, 25,4 % au Canada) : la carte choroplèthe de l'application (`px.choropleth`) montre donc surtout où se trouve le volume, pas un écart de qualité entre marchés.

5.3 Distribution de l'engagement par appareil

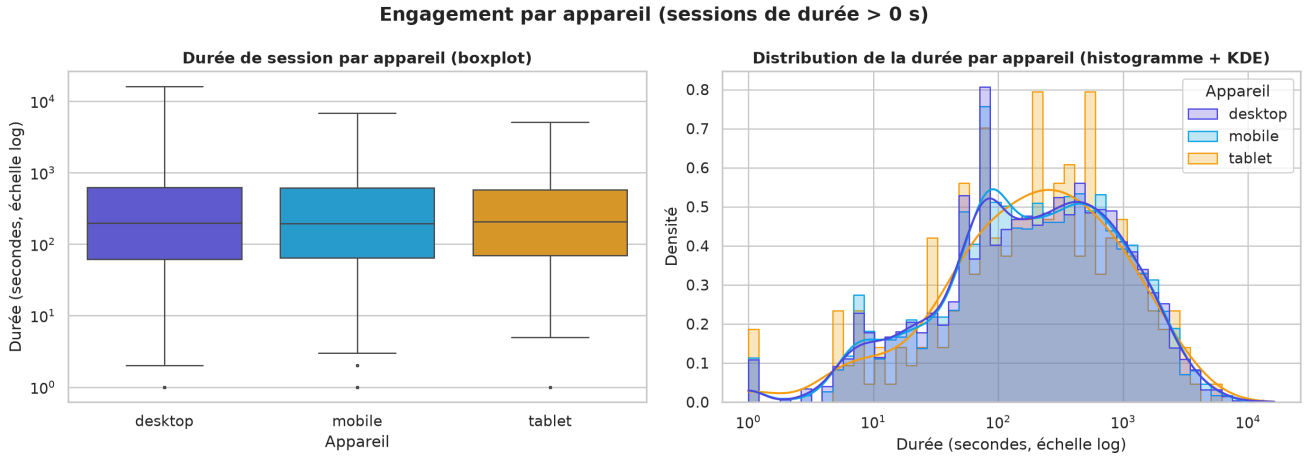


Figure 4. Durée de session par appareil, en échelle logarithmique. À gauche `sns.boxplot`, à droite `sns.histplot(kde=True)` avec une aire normalisée par appareil. Les sessions de durée nulle sont exclues de ces deux graphiques seulement. Dans l'application : `px.box` et `px.histogram`, pour la durée, le nombre d'actions ou la valeur du panier. Source : notebook, section 10.3.

32,7 %
des sessions (5 922) ont une durée nulle : un seul horodatage ; 33,0 % desktop, 32,3 % mobile, 33,3 % tablet

197 / 196 / 208 s
durées médianes desktop / mobile / tablet, parmi les sessions de durée positive

580 à 627 s
troisième quartile selon l'appareil ; maximum 16 196 s sur desktop, 6 895 s sur mobile

Lecture. Les trois boîtes sont presque superposées et les densités ont la même forme. La seule différence visible est l'extrémité de la queue, plus longue sur desktop. L'histogramme de la tablette est plus irrégulier car il ne repose que sur 254 sessions de durée positive.

Interprétation. La densité est **bimodale** : un premier mode vers 80 s correspond à des visites éclairs (un ou deux ajouts au panier), un second, plus large, entre 200 et 1000 s, à des sessions de composition de panier. Ces deux usages existent sur chaque appareil dans les mêmes proportions : **l'appareil ne différencie pas l'engagement** dans ce jeu. La densité de la valeur du panier le confirme, avec un panier médian identique de 382 USD sur les trois appareils (valeur qui reflète l'artefact d'obfuscation décrit en section 8).

5.4 Heatmap heure x jour de la semaine

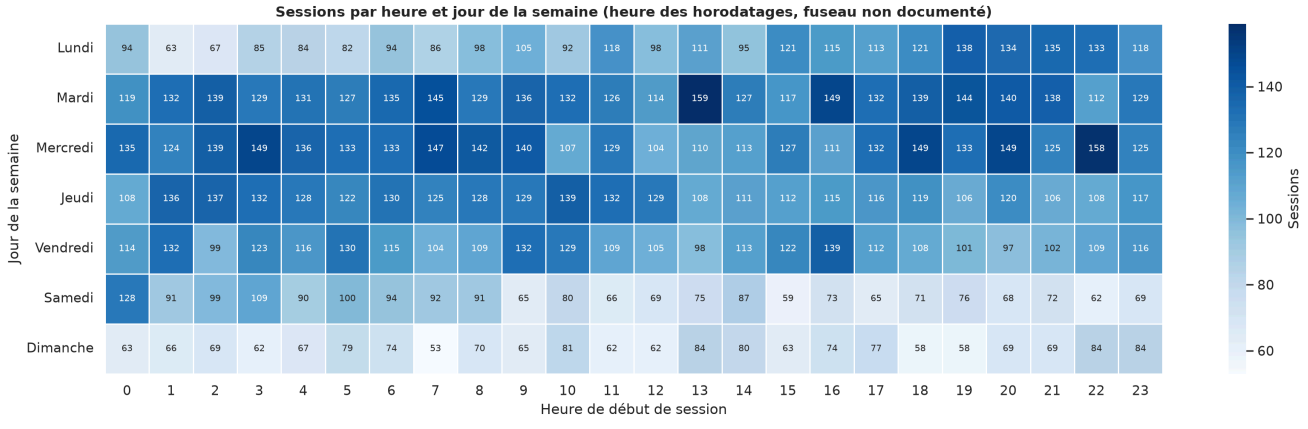


Figure 5. Sessions selon l'heure et le jour de début de session. `sns.heatmap(annot=True, cmap="Blues")` : palette séquentielle à une seule teinte, adaptée à des effectifs. Grille complète de 7 × 24 cases. Dans l'application : `px.imshow`. Source : notebook, section 10.4.

3 180 contre 1673
sessions le mardi et le dimanche, soit un rapport de 1,9

20,0 %
des sessions seulement ont lieu le week-end (samedi 1951, dimanche 1673)

681 à 789
sessions selon l'heure (12 h et 3 h) ; case maximale : mardi à 13 h, 159 sessions

Lecture. Les lignes du samedi et du dimanche sont les plus claires à presque toutes les heures, tandis que celles du mardi et du mercredi (3 180 et 3 150 sessions) sont les plus foncées. Les colonnes, elles, se ressemblent : aucun creux nocturne ne se dessine.

Interprétation. Le jour de la semaine structure le trafic, l'heure presque pas. Le profil de semaine est compatible avec des achats faits depuis le bureau ou pour l'entreprise. L'absence de cycle jour et nuit est en revanche surprenante pour une audience à 44 % américaine : elle peut venir de la diversité des fuseaux des visiteurs ou de l'obfuscation des horodatages, d'autant que le fuseau des données n'est pas documenté. Les conclusions horaires se lisent donc comme des tendances relatives, et les recommandations portent sur le jour plutôt que sur l'heure.

5.5 Compléments : entonnoir de conversion et corrélations

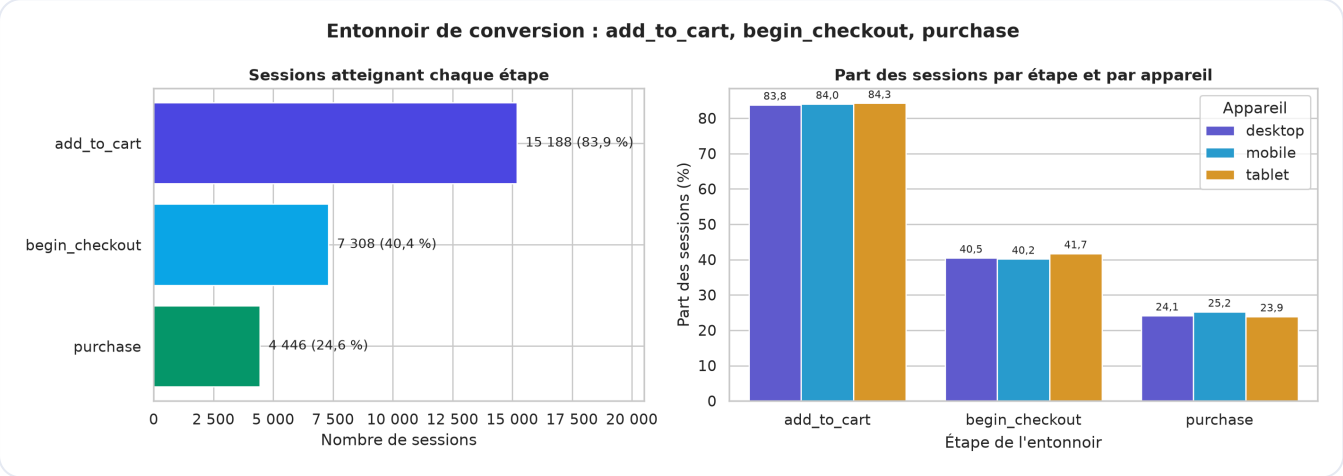


Figure 6. Entonnoir de conversion, global et par appareil. Une session compte pour une étape si elle contient au moins un événement de ce type. Dans l'application : `px.funnel` empilé par appareil. Source : notebook, section 10.6.

Lecture. 15 188 sessions (83,9 %) contiennent un ajout au panier, 7 308 (40,4 %) un début de paiement et 4 446 (24,6 %) un achat, avec des parts quasi identiques sur les trois appareils. L'entonnoir n'est cependant pas un chemin strict : 2 913 sessions n'ont aucun `add_to_cart`, dont 1 993 qui commencent pourtant un paiement, et 1 006 sessions achètent sans `begin_checkout`. Le rapport des effectifs d'une étape à l'autre n'est donc pas une probabilité de passage ; on calcule des **taux conditionnels** sur les mêmes sessions.

Passage	Taux conditionnel
`add_to_cart` vers `begin_checkout`	35,0 %
`begin_checkout` vers `purchase`	47,1 %
`add_to_cart` vers `purchase`	16,9 %

Interprétation. La plus grosse perte se situe **entre le panier et le paiement** : 65,0 % des sessions avec ajout au panier s'arrêtent là, contre 52,9 % entre paiement et achat. C'est le panier, plus encore que le tunnel de paiement, qu'il faut travailler.

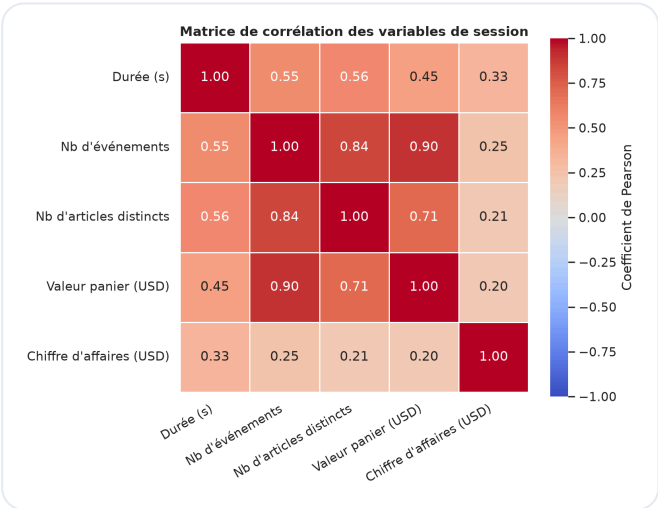


Figure 7. Corrélations de Pearson entre variables de session. `sns.heatmap`, palette divergente. Source : notebook, section 10.5.

Corrélations. Le nombre d'événements et la valeur du panier sont très liés (0,90), en partie mécaniquement : 92,6 % des événements sont des ajouts au panier. La durée et le nombre d'événements ne sont corrélés qu'à 0,55 en Pearson mais à 0,71 en Spearman : la relation est croissante mais non linéaire. Surtout, **le chiffre d'affaires est faiblement corrélé à tout le reste** (0,20 à 0,33) : une session longue et chargée ne garantit pas un achat, ce qui rejoint le constat de l'entonnoir.

ÉTAPE 4 DU CAHIER DES CHARGES

06 Le tableau de bord Audience Lab

L'application Streamlit rassemble toutes les analyses sur une page : une barre latérale de filtres, un bandeau de six indicateurs toujours visible et six onglets qui reprennent les quatre questions directrices. Elle est en ligne à l'adresse https://audience-lab.streamlit.app.



Figure 8. Accueil en thème clair. À gauche, les filtres (`st.sidebar`) et l'export CSV ; en haut, les six `st.metric` avec leur variation et leur petite courbe ; en dessous, l'onglet Synthèse et ses constats rédigés automatiquement à partir des données filtrées.



Figure 9. Temporalité. Courbe `px.line` (jour ou semaine, détail par appareil) avec repères calendaires ; la heatmap heure x jour suit dans l'onglet.

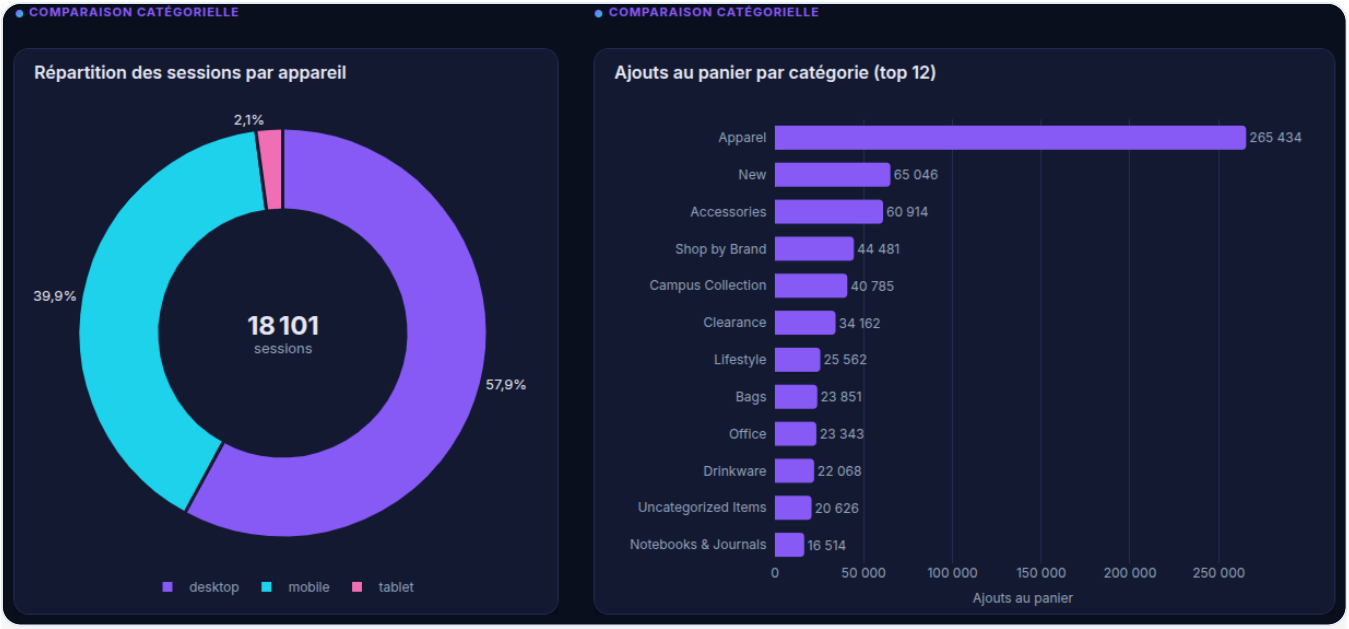


Figure 10. Audience. Anneau des appareils et barres des catégories (ajouts au panier ou chiffre d'affaires) ; la carte et le top 10 des pays suivent dans l'onglet.

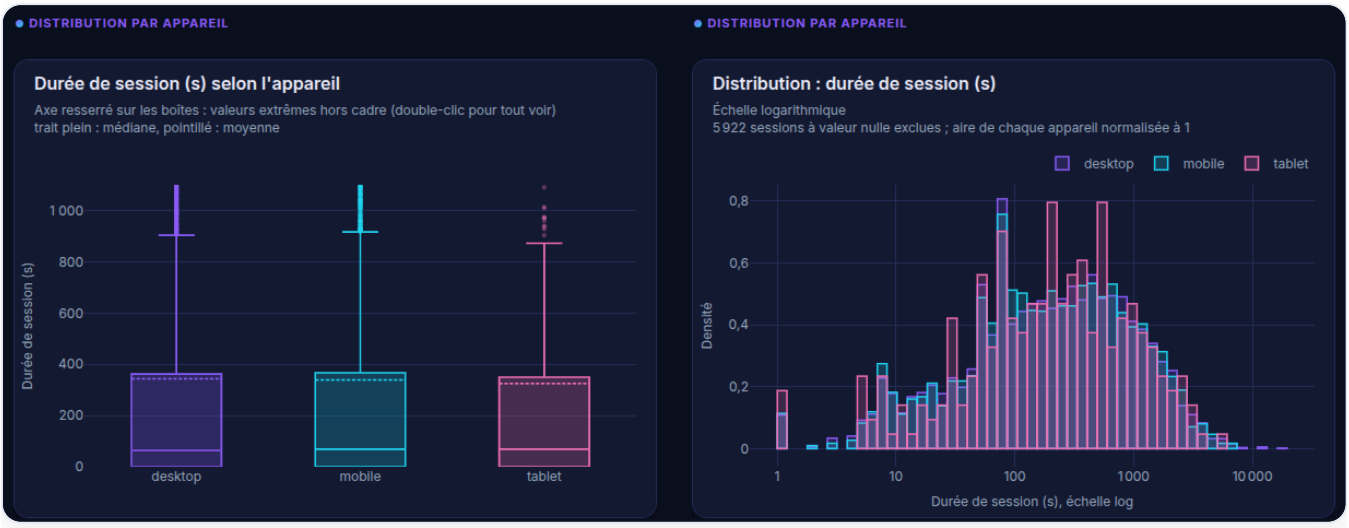


Figure 11. Engagement. Boîtes et distributions par appareil pour trois métriques, avec échelle logarithmique activable.



Figure 12. Conversion. Entonnoir empilé par appareil et cartes de conversion par appareil, avec l'étape de plus forte perte calculée.

Fonctionnalités et API du cours

Exigence du sujet	Mise en œuvre dans `app.py`
Filtrage dynamique (`st.sidebar`)	période (plage de dates bornée aux données), appareils, pays (classés par fréquence), catégories ; bouton « Réinitialiser les filtres »
Métriques clés (`st.metric`)	sessions, utilisateurs, durée moyenne, panier moyen, taux de conversion, part mobile ; variation et petite courbe quotidienne
Graphiques Plotly Express (`st.plotly_chart`)	`px.line`, `px.imshow`, `px.pie`, `px.bar`, `px.choropleth`, `px.box`, `px.histogram`, `px.funnel` ; survol en valeurs réelles, export PNG
Export CSV (`st.download_button`)	sessions filtrées, toutes colonnes, encodage UTF-8 avec BOM (lisible par Excel) ; aussi proposé dans l'onglet Données

Choix de conception

Deux thèmes cohérents

Un thème sombre par défaut, adapté à la projection, et un thème clair, au choix par une bascule. Le CSS et chaque figure Plotly (fond, texte, palette) suivent le thème ; les couleurs des appareils restent identiques d'un graphique à l'autre.

Des variations honnêtes

Chaque carte compare la sélection à la période précédente de même durée. Si celle-ci sort des données, ce qui est le cas de la vue par défaut, l'application compare la seconde moitié de la période à la première et l'annonce en clair ; un seul jour sélectionné n'affiche pas de variation.

Lisible et robuste

Typographie française (espaces insécables, virgule décimale), valeurs de données en anglais, légende chiffrée sous chaque graphique, message « Aucune donnée pour ces filtres » au lieu d'une erreur. Une page « Données » montre l'aperçu des sessions filtrées.

Rapide en ligne

Données en Parquet, chargement et filtrage mis en cache (`st.cache_data`), onglets calculés seulement à l'ouverture : de 0,1 à 0,4 s par interaction en local. 95 tests automatisés couvrent données, indicateurs, graphiques et application.

CE QUE L'ANALYSE CHANGE POUR LA BOUTIQUE

07 Conclusions business

Les constats convergent : l'audience se joue sur quelques semaines de fin d'année et en semaine, elle se comporte de la même façon quel que soit l'appareil, et la boutique perd l'essentiel de ses acheteurs potentiels entre le panier et le paiement. Six recommandations en découlent, de la plus à la moins prioritaire.

1

Préparer la fenêtre du 23 novembre au 18 décembre

Ces 26 jours (28 % de la période) concentrent 9 744 sessions, soit 53,8 % du trafic. Les campagnes doivent être lancées avant le Black Friday, les stocks des best-sellers sécurisés pour début décembre et les dates limites de livraison mises en avant, puisque le pic coïncide avec les commandes de Noël et non avec le Black Friday lui-même.

Appui : figure 2 ; record de 527 sessions le 8 décembre ; 87 sessions le jour de Noël.

2

Réduire l'abandon entre le panier et le paiement

Seules 35,0 % des sessions avec ajout au panier commencent un paiement, alors que 47,1 % des paiements commencés aboutissent. Les leviers relèvent du panier : frais et délais de livraison affichés dès le panier, relance des paniers abandonnés (le panier est souvent constitué puis payé plus tard), bouton de paiement express. À suivre avec le taux conditionnel `add_to_cart` vers `begin_checkout` comme indicateur principal.

Appui : figure 6 ; 65,0 % de perte à cette étape ; 1,7 % de la valeur ajoutée au panier est achetée.

3

Programmer les actions en semaine

Mardi et mercredi sont les jours les plus actifs, le week-end ne pèse que 20,0 % des sessions. Les envois de courriels, mises en avant et lancements de produits gagnent à être planifiés en début de semaine. L'heure, peu discriminante et de fuseau incertain, ne justifie pas d'optimisation fine à ce stade.

Appui : figure 5 ; mardi 3 180 sessions contre 1 673 le dimanche.

4

Traiter le mobile à parité, pas comme un problème

Le mobile convertit au moins aussi bien que le desktop (25,2 % contre 24,1 %) et pèse 40,2 % du chiffre d'affaires. Aucun écart de comportement ne justifie un chantier mobile spécifique ; l'enjeu est de maintenir la parité, en testant chaque évolution du tunnel d'achat sur les deux supports.

Appui : tableau des appareils (section 4) ; figure 4 ; durées médianes de 64 à 69 s.

5

Piloter l'assortiment par la transformation, pas seulement par le volume

`Apparel` reste le pilier (54,3 % du chiffre d'affaires) et doit être protégé en stock. `Bags` transforme mieux ses ajouts au panier (2,81 achats pour 100 contre 1,83) : il mérite davantage de visibilité. `Notebooks & Journals`, avec 16 514 ajouts pour 36 achats, appelle un audit (prix, disponibilité, fiche produit, éventuel défaut de suivi).

Appui : figure 3 et tableau des catégories (section 5.2).

6

Considérer l'Inde et le Canada comme des relais de croissance

Hors États-Unis (44,2 % des sessions), l'Inde (9,2 %) et le Canada (7,8 %) convertissent au même niveau (24,9 % et 25,4 %). Une offre localisée (affichage des prix, conditions de livraison) y aurait un rendement comparable à celui du marché principal.

Appui : tableau des pays (section 4) ; carte de l'onglet Audience.

Indicateurs de pilotage proposés

Indicateur	Valeur de référence	Pourquoi le suivre
Passage `add_to_cart` vers `begin_checkout`	35,0 %	mesure directe de la recommandation 2
Passage `begin_checkout` vers `purchase`	47,1 %	santé du tunnel de paiement
Taux de conversion des sessions	24,56 %	indicateur global, déjà dans le bandeau
Panier moyen (sessions avec achat)	65,09 USD	valeur unitaire des commandes
Écart de conversion mobile et desktop	+1,1 point	alerte si la parité se dégrade

Ces valeurs de référence portent sur la période complète. Le tableau de bord permet de les recalculer sur n'importe quelle période, appareil, pays ou catégorie, et d'en suivre la variation.

RECUL CRITIQUE

08 Conclusions techniques et limites

Conclusions techniques

- **Une chaîne reproductible.** Du téléchargement contrôlé des fichiers bruts à l'export Parquet, chaque étape est scriptée et chiffrée ; le notebook s'exécute de bout en bout et produit les figures de ce rapport.
- **La session, bon niveau d'analyse.** Passer de 719 386 événements à 18 101 sessions a rendu calculables la durée, la valeur du panier et l'entonnoir, et a révélé que `ga_session_id` seul n'est pas un identifiant de session.
- **Des statistiques robustes à l'asymétrie.** Médiane plutôt que moyenne pour la durée, échelle logarithmique, corrélation de Spearman et taux conditionnels pour l'entonnoir : les choix de représentation ont évité plusieurs conclusions trompeuses.
- **Un format adapté au déploiement.** Le Parquet divise par neuf environ le volume (41,7 Mo de CSV contre 4,8 Mo) en conservant les types ; avec la mise en cache, l'application reste fluide sur Streamlit Community Cloud.
- **Une application testée.** 95 tests pytest vérifient les données traitées, les indicateurs, les constats, les graphiques (y compris les filtres vides et le suivi du thème) et l'application elle-même.

Limites des données

Limite	Constat chiffré	Conséquence pour l'analyse
Fuseau horaire non documenté	La source ne précise pas le fuseau des horodatages, probablement celui de la propriété Google Analytics (États-Unis). Le profil horaire est anormalement plat : 681 à 789 sessions selon l'heure.	Analyses horaires lues comme tendances relatives ; recommandations fondées sur le jour.
Échantillon obfusqué	Google anonymise ce jeu public : 6 155 sessions (34,0 %) contiennent exactement 12 articles distincts et les paniers de 191 et 382 USD sont surreprésentés (panier médian de 382 USD sur chaque appareil).	Niveaux absolus de panier à prendre avec prudence ; comparaisons relatives conservées.
Sessions à durée nulle	5 922 sessions (32,7 %) n'ont qu'un horodatage : leur durée réelle est inconnue.	Durée moyenne et médiane sous-estimées ; ces sessions sont exclues des seules figures en échelle log.
Valeur ajoutée au panier et dépense	938,63 USD ajoutés au panier par session contre 15,99 USD de chiffre d'affaires ; un article ajouté plusieurs fois compte plusieurs fois.	Indicateur d'intérêt, jamais présenté comme une dépense.

Limite	Constat chiffré	Conséquence pour l'analyse
Collecte incomplète en début de période	Avant le 16 novembre, seuls les achats sont enregistrés (600 sessions, 99,8 % avec achat, 13,3 % du chiffre d'affaires) ; le pic des 17 et 18 novembre (287 et 229 sessions) suit immédiatement le démarrage de la collecte des ajouts au panier ; `begin_checkout` n'apparaît que le 23 novembre. 953 des 1006 achats sans début de paiement sont antérieurs à cette date.	Conversion globale légèrement surestimée ; entonnoir stable si l'on part du 23 novembre (voir ci-dessous).
Événements e-commerce seulement	Pas de pages vues ni de source de trafic : une session est ici une visite comportant au moins un ajout au panier, un paiement ou un achat.	Les visiteurs qui ne font que regarder sont invisibles ; pas d'analyse d'acquisition possible.

TEST DE ROBUSTESSE DE L'ENTONNOIR

En limitant l'analyse aux 16 702 sessions démarrées à partir du 23 novembre, date où les trois types d'événements sont collectés, le taux de conversion descend à 20,9 %, mais les taux conditionnels restent du même ordre : 36,3 % des sessions avec panier commencent un paiement (35,0 % sur la période complète) et 47,1 % des paiements aboutissent (identique). Il ne reste alors que 53 achats sans `begin_checkout`. **La conclusion principale, une perte concentrée entre panier et paiement, ne dépend donc pas de ce défaut de collecte.** Calcul complémentaire réalisé pour ce rapport à partir de `data/processed/`.

Limites de l'outil et pistes d'amélioration

- **Hébergement gratuit.** Streamlit Community Cloud met l'application en veille après une période d'inactivité ; le premier chargement peut prendre quelques secondes.
- **Dépendance à la version de Streamlit.** Le CSS personnalisé cible la structure interne de Streamlit 1.66, d'où la version figée dans `requirements.txt`.
- **Pistes.** Exploiter `users.csv` pour une analyse de cohortes et de valeur vie client ; ajouter un raccourci « à partir du 23 novembre » pour neutraliser le défaut de collecte ; confirmer le fuseau horaire auprès de la source ; enrichir les données avec les pages vues et les sources de trafic pour relier l'audience à l'acquisition.

POUR REPRODUIRE ET VÉRIFIER

A Annexes

A.1 Exécution locale

Prérequis : Python 3.12 et Git. Les données brutes et traitées sont versionnées : l'application démarre sans étape préalable.

```
# 1. Récupérer le projet et créer l'environnement
git clone https://github.com/Abdazz/audience-lab.git
cd audience-lab
python3 -m venv .venv
source .venv/bin/activate
pip install -r requirements-dev.txt   # requirements.txt suffit pour l'application seule
# 2. Lancer le tableau de bord (http://localhost:8501)
streamlit run app.py
# 3. Facultatif : retélécharger les données brutes et réexécuter le notebook
python scripts/telecharger_donnees.py
jupyter nbconvert --to notebook --execute --inplace notebooks/01_preparation_donnees.ipynb
# 4. Lancer les tests, puis régénérer ce rapport (Chromium et pdftotext requis)
pytest -q
scripts/generer_pdf.sh rapport/rapport_analyse.html rapport/rapport_analyse.pdf
```

A.2 Arborescence du dépôt

```
audience-lab/
├── app.py                          # point d'entrée Streamlit
├── audience/                       # données, KPI, constats, graphiques, thèmes
│   └── donnees.py, kpis.py, constats.py, graphiques.py, theme.py
├── data/
│   ├── raw/                        # events.csv, items.csv, users.csv (source)
│   └── processed/                  # events_clean.parquet, sessions.parquet
├── notebooks/01_preparation_donnees.ipynb
├── rapport/                        # ce rapport (HTML, CSS, PDF) et figures/
├── soutenance/                     # support de l'oral et déroulé de la démonstration
│   └── presentation.html, presentation.pdf, deroule_demo.md
├── scripts/                        # téléchargement des données, génération du PDF
├── tests/                          # 95 tests pytest
├── docs/captures/                  # captures d'écran de l'application
├── .streamlit/config.toml
├── README.md                       # présentation, captures, liens, exécution
├── requirements.txt                # versions exactes
└── requirements-dev.txt            # + Jupyter, pytest
```

A.3 Correspondance avec les exigences du sujet

Exigence	Où la trouver
1.1 Variables temporelle, numériques, catégorielles	Rapport 2.3 ; notebook, sections 1 et 6
2.1.1 Inspection, valeurs manquantes et aberrantes	Rapport 3 ; notebook, sections 1, 2, 3 et 8
2.1.2 Conversion en `datetime`, indexation temporelle	Notebook, section 4 (`pd.to_datetime`, `set_index`, `resample`)
2.1.3 Variables agrégées (heure, jour, mois)	Notebook, sections 6 et 7
2.2 KPI : volume, durée ou valeur moyenne, répartition	Rapport 4 ; notebook, section 9 ; bandeau `st.metric`
2.3.1 Évolution temporelle avec filtres	Rapport 5.1 ; onglet Temporalité (`px.line`)
2.3.2 Comparaison catégorielle (barres ou camembert)	Rapport 5.2 ; onglet Audience (`px.bar`, `px.pie`)
2.3.3 Distribution par appareil (boxplot ou densité)	Rapport 5.3 ; onglet Engagement (`px.box`, `px.histogram`)
2.3.4 Heatmap heures x jours	Rapport 5.4 ; onglet Temporalité (`px.imshow`)
2.4 `st.sidebar`, `st.metric`, `st.plotly_chart`, `st.download_button`	Rapport 6 ; `app.py`, sections 4 à 6
3.1 Code source propre et commenté, notebook	`app.py`, `audience/`, `notebooks/` ; dépôt GitHub
3.2 Rapport d'analyse	Présent document (`rapport/rapport_analyse.pdf`)
3.3 Démonstration orale	Application en ligne ; support dans `soutenance/`

A.4 Sources et références

- Google, *Google Analytics 4 ecommerce sample dataset*, jeu public BigQuery `bigquery-public-data.ga4_obfuscated_sample_ecommerce`.
- Observable, *Google Merchandise Sales Data*, `@observablehq/google-merchandise-sales-data` ; reprise Kaggle `mexwell/google-merchandise-sales-data`.
- J. W. Tukey, *Exploratory Data Analysis*, Addison-Wesley, 1977 (règle des 1,5 x IQR).
- Code et données du projet : https://github.com/Abdazz/audience-lab ; application : https://audience-lab.streamlit.app.